

Tarea 2: Aproximación con SVD y aplicaciones

Francisco Vera

13 de junio de 2026

P1. Pregunta Teórica

Demostremos la proposición 7.92 del libro Linear Algebra Done Right que establece que la mejor aproximación de rango k a una transformación $T \in \mathcal{L}(V, W)$ es dada por su descomposición en valores singulares (SVD). Es decir, para toda transformación $S \in \mathcal{L}(V, W)$ con $\dim(\text{Range}(S)) \leq k$, se cumple:

$$\|T - S\| \geq \sigma_{k+1}$$

Demostración:

La descomposición en valores singulares (SVD) dice que si $T \in \mathcal{L}(V, W)$ tiene valores singulares positivos $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_m > 0$, existen listas ortonormales $e_1, \dots, e_m$ en V y $f_1, \dots, f_m$ en W tales que:

$$Tv = \sum_{i=1}^m \sigma_i \langle v, e_i \rangle f_i \quad \text{para todo } v \in V.$$

Supongamos $S \in \mathcal{L}(V, W)$ tal que $\dim(\text{Range}(S)) \leq k$. Consideremos los primeros $k+1$ vectores de la lista ortonormal del dominio: $e_1, \dots, e_{k+1}$. Al aplicarles la transformación S , obtenemos la lista de vectores $Se_1, \dots, Se_{k+1}$ en el espacio W . Como esta lista tiene longitud $k+1$ y está contenida en el rango de S (el cual tiene dimensión a lo más k), este conjunto de vectores debe ser linealmente dependiente (7.92 del libro).

Por la dependencia lineal del paso anterior, existen escalares $a_1, \dots, a_{k+1} \in \mathbb{F}$ (no todos iguales a cero), tales que:

$$a_1 Se_1 + \dots + a_{k+1} Se_{k+1} = 0. \quad (7.92 \text{ del libro})$$

A partir de estos coeficientes, construimos el vector $u \in V$ como:

$$u = a_1 e_1 + \dots + a_{k+1} e_{k+1}.$$

Nota que $u \neq 0$ porque $e_1, \dots, e_{k+1}$ son vectores linealmente independientes (por ser ortonormales) y los escalares a_i no son todos cero. Además, por linealidad:

$$Su = 0$$

Ahora veamos la norma de $(T - S)u$. Por la definición de u y $Su = 0$, tenemos que:

$$\|(T - S)u\|^2 = \|Tu - Su\|^2 = \|Tu\|^2.$$

Luego, calculemos Tu :

$$Tu = T(a_1 e_1 + \dots + a_{k+1} e_{k+1}) = \sum_{i=1}^{k+1} a_i T e_i.$$

Utilizando la definición de SVD, sabemos que $Te_i = \sigma_i f_i$ (para $i \leq m$). Entonces:

$$Tu = \sum_{i=1}^{k+1} a_i \sigma_i f_i.$$

Ahora evaluamos la norma al cuadrado. Dado que la lista $f_1, \dots, f_{k+1}$ es ortonormal, la norma al cuadrado de la combinación lineal es igual a la suma de los cuadrados de los coeficientes:

$$\|Tu\|^2 = \left\| \sum_{i=1}^{k+1} a_i \sigma_i f_i \right\|^2 = \sum_{i=1}^{k+1} \sigma_i^2 |a_i|^2.$$

Sabemos que $\sigma_i^2 \geq \sigma_{k+1}^2$ para cada $i \in \{1, \dots, k+1\}$. Entonces:

$$\sum_{i=1}^{k+1} \sigma_i^2 |a_i|^2 \geq \sum_{i=1}^{k+1} \sigma_{k+1}^2 |a_i|^2 = \sigma_{k+1}^2 \sum_{i=1}^{k+1} |a_i|^2.$$

$\sum_{i=1}^{k+1} |a_i|^2$, es la norma al cuadrado del vector u (ya que los vectores e_i son ortonormales). Entonces:

$$\|(T - S)u\|^2 \geq \sigma_{k+1}^2 \|u\|^2.$$

Sacando raíz cuadrada a la desigualdad, tenemos que $\|(T - S)u\| \geq \sigma_{k+1} \|u\|$. Por definición, la norma $\|T - S\|$ es el máximo estiramiento posible. Como el vector u es no nulo ($u \neq 0$), entonces:


$$\|T - S\| \geq \frac{\|(T - S)u\|}{\|u\|} \geq \sigma_{k+1}.$$

Con esto se prueba que $\|T - S\| \geq \sigma_{k+1}$.

P2. Pregunta Numérica (SVD con Olivetti Faces)


Se mostraran las interpretaciones de la aplicación de SVD sobre el dataset Olivetti Faces.

(a) Valores singulares y varianza explicada



La curva de valores singulares cae drásticamente en las primeras componentes, lo que confirma que la mayor parte de la información (diferencias de la cara) está fuertemente correlacionada y concentrada en muy pocas dimensiones. Aunque cada imagen está en un espacio de 4096 dimensiones (64×64 píxeles), se requiere de $k = 66$ componentes para explicar el 90 % de la varianza y explicar el 99 % requiere $k = 260$ componentes. La diferencia de casi 200 componentes entre 90 % y 99 % puede indicar que el último 9 % de la información podría corresponder a ruido o detalles de cada cara.

(b) Eigen-imágenes




Se puede ver que la cara promedio representa la cara "base" que se obtiene promediando todas las imágenes.

Se puede ver que EF 1 captura principalmente la iluminación y brillo de las fotos. En EF 2 se puede ver que está capturando en qué dirección está llegando la luz en las fotos. En EF 3 y EF 4 ya se están capturando las primeras facciones de la cara que son la frente, el contorno de los ojos y la boca de la cara. En EF 5 y 6 ya se marcan claramente la boca, nariz y ojos.

(c) Reconstrucción progresiva

Se puede observar que:



De $k = 1$ a $k = 5$ la imagen no es tan reconocible, es prácticamente la cara "base". De $k = 10$ a $k = 20$ las proporciones de la cara empiezan a ser mas claras. De $k = 50$ a $k = 66$ ya se empiezan a ver claramente las facciones de la cara de la persona. En $k = 66$ (90 % de varianza), se puede ver claramente a la persona. De $k = 100$ hasta $k = 266$ las mejoras en la cara son casi indistinguibles. En ese punto, las mejoras son de disminución de ruido y mejoras en la nitidez de la imagen.

Link repositorio GitHub

<https://github.com/Fi-Vera/IMT2230/tree/main/Tarea2>